

RAPPORT DE TP Fouille de donnees

Sujet : Amelioration de l'algorithme K-means

Traitement dynamique des points frontieres

1 Introduction

L'algorithme K-means est une methode classique de clustering non supervise. Son objectif est de regrouper les donnees en plusieurs groupes appeles clusters, de maniere a ce que les objets appartenant au meme cluster soient proches entre eux, tandis que les clusters soient bien separes.

Dans l'approche classique, chaque point est affecte directement au centre le plus proche. Cette strategie est simple et efficace, mais elle presente une limite importante : certains points peuvent se trouver presque a la meme distance de deux centres differents. Ces points sont appeles points frontieres ou points ambigus.

L'objectif de ce travail est de proposer une amelioration de K-means basee sur le traitement dynamique des points frontieres. L'idee consiste a detecter les points ambigus, puis a tester leur reaffectation vers le deuxieme cluster le plus proche, uniquement si ce deplacement reduit l'erreur locale.

2 Methodologie : l'approche amelioree

2.1 Donnees utilisees

Les experimentations ont ete realisees sur le fichier Mall_Customers.csv. Ce jeu de donnees contient 200 clients et 5 colonnes. Apres suppression de la colonne identifiant CustomerID et encodage de la variable categorielle Gender, le jeu de donnees utilise par l'algorithme contient 5 variables numeriques.

Les attributs utilises decrivent les caracteristiques des clients, notamment le genre, l'age, le revenu annuel et le score de depense. Avant l'application de K-means, les donnees ont ete normalisees afin d'eviter qu'une variable ayant de grandes valeurs domine le calcul des distances.

2.2 Principe du K-means classique

Le K-means classique suit les etapes suivantes : choisir un nombre de clusters K, initialiser les centres, affecter chaque point au centre le plus proche, recalculer les centres, puis repeter jusqu'a stabilisation. Dans cette experience, le K-means classique est utilise avec $K = 2$ et sert de base de comparaison.

2.3 Principe du K-means avec points frontieres

L'amelioration proposee agit sur la phase d'affectation des points. Pour chaque point, l'algorithme calcule deux distances : $d1$, la distance entre le point et le centre le plus proche, et $d2$, la distance entre le point et le deuxieme centre le plus proche.

Si ces deux distances sont proches, le point est considere comme ambigu. On calcule alors un score d'ambiguite : $A = (d2 - d1) / (d1 + \epsilon)$. Plus ce score est faible, plus le point est proche de la frontiere entre deux clusters.

L'amelioration est dite dynamique, car le seuil de detection des points frontieres n'est pas fixe. Au debut, l'algorithme traite les 20 % des points les plus ambigus, puis ce pourcentage diminue progressivement jusqu'a 5 %. Une reaffectation est acceptee seulement si elle reduit l'erreur locale des clusters concernes.

3 Etude comparative des performances

3.1 Analyse numerique des resultats

La comparaison a ete realisee entre une version classique de K-means avec $K = 2$ et une version amelioree avec traitement dynamique des points frontieres. Cette derniere teste automatiquement les valeurs de K entre 2 et 10. La meilleure valeur obtenue est $K = 10$.

Metrique	K-means classique	K-means ameliore	Variation
K utilise	2	10	-
Inertie	597.9473	152.5901	-74.48 %
Silhouette	0.3964	0.4383	+10.55 %
Davies-Bouldin	1.1425	0.8160	-28.58 %
Calinski-Harabasz	133.1329	117.2407	-11.94 %
Distance intra	1.6185	0.7990	-50.63 %
Distance inter	2.8563	3.0250	+5.91 %
Ratio inter/intra	1.7648	3.7858	+114.52 %
Balance	0.8800	0.6500	-26.14 %
Temps total	4.0181 s	0.9521 s	-76.31 %

On remarque que la version amelioree reduit fortement l'inertie, ce qui signifie que les points sont plus proches de leurs centres. La distance intra-classe diminue egalement de maniere importante, ce qui montre que les clusters obtenus sont plus compacts.

Le score silhouette augmente de 10.55 %, ce qui indique une meilleure affectation globale des points aux clusters. L'indice Davies-Bouldin diminue aussi, ce qui est positif, car une valeur plus faible signifie des clusters mieux separes et plus homogenes.

Le ratio inter/intra passe de 1.7648 a 3.7858, soit une amelioration de 114.52 %. Cela montre que les clusters obtenus par la version amelioree sont a la fois plus compacts a l'interieur et mieux separes entre eux. Cependant, l'indice Calinski-Harabasz diminue legerement, et la balance des clusters est moins bonne.


3.2 Activite de correction des points frontieres

L'approche amelioree ne se contente pas de changer la valeur de K . Elle applique reellement une correction locale sur les points ambigus. Les resultats montrent que l'algorithme a traite 292 points frontieres et a accepte 64 reassignments.

Cela signifie que tous les points frontieres detectes ne sont pas deplaces. L'algorithme teste chaque deplacement et ne l'accepte que s'il reduit l'erreur locale. Cette strategie evite les corrections inutiles ou negatives.


4 Representation graphique des resultats

Figure 1. Choix automatique de K par score silhouette.




La premiere figure represente l'evolution du score silhouette en fonction du nombre de clusters K. Le score diminue legerement entre K = 2 et K = 6, puis augmente progressivement a partir de K = 7. Le meilleur score est obtenu pour K = 10, avec une silhouette d'environ 0.4383. Cette figure justifie donc le choix automatique de K = 10 pour la version amelioree.

Figure 2. Activite de correction des points frontieres.



La deuxieme figure montre le nombre de points frontieres detectes et le nombre de reaffectations acceptees. On observe que le nombre de points frontieres augmente globalement lorsque K augmente. Pour K = 10, l'algorithme traite 292 points frontieres et accepte 64 reaffectations.

Figure 3. Comparaison entre K-means classique et K-means avec points frontieres.



La troisieme figure compare les deux approches selon plusieurs mesures : silhouette, distance intra, distance inter, ratio inter/intra et balance. La version amelioree obtient une meilleure silhouette, une distance intra beaucoup plus faible, une distance inter legerement plus elevee et un ratio inter/intra nettement superieur. La seule metrique qui diminue est la balance.

5 Conclusion

L'approche amelioree proposee dans ce travail consiste a ajouter au K-means une etape de traitement dynamique des points frontieres. Contrairement au K-means classique, qui affecte directement chaque point au centre le plus proche, cette version detecte les points ambigus proches de deux centres, puis teste une reaffectation locale.

Les resultats obtenus sur Mall_Customers.csv montrent une amelioration nette de plusieurs mesures. L'inertie est reduite de 74.48 %, la distance intra-classe diminue de 50.63 %, et le ratio inter/intra augmente de 114.52 %. Le score silhouette progresse egalement de 10.55 %, ce qui indique une meilleure qualite globale du clustering.

L'algorithme a aussi traite 292 points frontieres et accepte 64 reaffectations, ce qui confirme que la correction dynamique a reellement participe a l'amelioration des resultats.

Cependant, cette amelioration n'est pas uniforme sur toutes les metriques. L'indice Calinski-Harabasz diminue legerement, et la balance des clusters est plus faible que dans le K-means classique. Cela s'explique principalement par le fait que la version amelioree produit un clustering plus detaille avec 10 clusters, alors que la version classique utilise seulement 2 clusters.

En conclusion, le K-means avec traitement dynamique des points frontieres constitue une amelioration interessante et defendable. Elle conserve la logique de base du K-means tout en ajoutant une phase de correction locale permettant d'obtenir des clusters plus compacts, mieux separes et plus adaptes a la structure reelle des donnees.